

© Pablo Vinuesa 2021. @pvinmex vinuesa{at}ccg{dot}unam{dot}mx https://www.ccg.unam.mx/~vinuesa/

Intoducción a la filoinformática – pan-genómica y filogenómica. Diplomado en Bioinformática UAS 2021 https://github.com/vinuesa/intro-filoinfo\_UAS

# Un tutorial sobre el uso de Modeltest3.7 y jModelTest2 para la selección de modelos usando LRTs, AICs y BICs

- Conviene que leas este tutorial después de haber estudiado el tutorial de manejo de PAUP\* desde la línea de comandos y el tema de teoría sobre el uso del criterio de máxima verosimilitud en filogenética.
- (j)Modeltest es una aplicación escrita por David Posada y colegas, que seleccionan el modelo mejor ajustado de la familia GTR para un alineamiento de DNA, usando dos tipos de estrategias: tests pareados de razones de verosimilitud (LRTs, hLRTs = hierarchical LRTs) y criterios de información (AIC y BIC).

  Para ello necesita que PAUP\* o PhyML calculen los -InL scores de un subconjunto (56) de todos los posibles modelos de la familia GTR (203). Estos scores de -InL se calculan corriendo un "batch file" de comandos PAUP\*. Lo primero que se estima es un árbol (rápido) NJ-JC69. Se usa la topología resultante para evaluar los distintos modelos y obtener estimas de ML de los parámetros correspondientes.

```
# >>>>>> Tutoral de uso de imodeltest2 <<<<<<<
# Pablo Vinuesa; http://www.ccg.unam.mx:/~vinuesa/
# 23 Nov. 2015.
# Para: Curso de Introduccion a la Bioinformatica
# Posgrado UNAM: semestre 2016-1
# 1. Instalacion: en tu $HOME, a~nade estas lineas al archivo .bashrc
# Aliases and ENV_VAR for JMODELTEST2.1.7
        # te lleva a tu $HOME
pico .bashrc # edita el archivo con pico
# al final del archivo copia estas dos lineas y guarda el archivo
export JMODELTEST HOME=/home/vinuesa/intro2bioinfo/jmodeltest-2.1.7
alias jmodeltest="java -jar $JMODELTEST_HOME/jModelTest.jar"
# teclea: (para hacer un sourcing al archivo de configuracion .bashrc, es decir,
     que el sistema lo vuelva a leer para cargar las nuevas instrucciones)
...bashrc
# Ahora comprobamos que podemos acceder a jmodeltest2 tecleando:
jmodeltest -help # debe desplegar la ayuda de jmodeltest2
```

```
# genera el un directorio de trabajo para este ejercicio
mkdir practica_jmodeltest && cd practica_jmodeltest
# haz liga simbolica al set de datos primate-mtDNA-interleaved1.phy en este directorio de trabajo
In -s /home/vinuesa/intro2bioinfo/seq_data/primate-mtDNA-interleaved1.phy
# explora el archivo
less primate-mtDNA-interleaved1.phy
# corre jmodeltest2 con los parametros abajo indicados
# -d datos
# -i usa modelos que asumen una proporcion de sitios invariantes
#-f usa modelos que asumen diferentes frecuencias de bases
#-g usa distribución gamma con 4 clases discretas de tasas para modelar
      la heterogeneidad de tasas de sustitucion intre sitios
#-AIC usa criterio de informacion de Akaike para la seleccion de modelos
jmodeltest -d primate-mtDNA-interleaved1.phy -i -f -g 4 -AIC
# Ahora corremos phyml bajo el mejor modelo seleccionado
phyml -i primate-mtDNA-interleaved1.phy -d nt -m 010010 -b -4 -f e -c 4 -a e --no_memory_check -o tlr -s
```

```
- interpretación de la salida de modeltest: 1. hLRTs (Continuación)
   Only two Tv rates
     Null model = K81uf
                                   -InL0 = 5973,2393
     Alternative model = TVM
                                   -lnL1 = 5938.5615
     2(InL1-InL0) = 69.3555
                                                df = 2
     P-value = <0.000001
    Equal rates among sites
     Null model = TVM
                                   -InL0 = 5938.5615
     Alternative model = TVM+G
                                  -lnL1 = 5709.6323
     2(InL1-InL0) = 457.8584
                                                df = 1
     Using mixed chi-square distribution
     P-value = <0.000001
    No Invariable sites
     Null model = TVM+G
                                   -InL0 = 5709.6323
     Alternative model = TVM+I+G -InL1 = 5709.6323
     2(lnL1-lnL0) = 0.0000
                                                df = 1
     Using mixed chi-square distribution
     P-value = >0.999999 es decir, no rechazo la H_0 !!! El modelo seleccionado es TVM+G
```

© Pablo Vinuesa 2021. @pvinmex vinuesa{at}ccg{dot}unam{dot}mx https://www.ccg.unam.mx/~vinuesa/

Intoducción a la filoinformática – pan-genómica y filogenómica. Diplomado en Bioinformática UAS 2021 https://github.com/vinuesa/intro-filoinfo\_UAS

```
- interpretación de la salida de modeltest: 1. hLRTs
       HIERARCHICAL LIKELIHOD RATIO TESTS (hLRTs)
  _____
  Confidence level = 0.01
  Equal base frequencies
                                -InL0 = 6424,2026
   Null model = JC
   Alternative model = F81
                               -lnL1 = 6284.9956
   2(lnL1-lnL0) = 278.4141
                                           df = 3
   P-value = <0.000001
   Ti=Tv
   Null model = F81
                               -lnL0 = 6284.9956
   Alternative model = HKY
                               -InL1 = 5981.7202
    2(InL1-InL0) = 606.5508
   P-value = <0.000001
   Equal Ti rates
   Null model = HKY
                               -lnL0 = 5981.7202
   Alternative model = TrN
                               -InL1 = 5978.8550
   2(\ln 1 - \ln 10) = 5.7305
   P-value = 0.016673
   Equal Tv rates
   Null model = HKY
                                -InL0 = 5981.7202
   Alternative model = K81uf
                               -lnL1 = 5973.2393
   2(lnL1-lnL0) = 16.9619
                                           df = 1
   P-value = 0.000038
                                                       (continúa en la siguiente página)
```

```
- interpretación de la salida de modeltest: 1. hLRTs (Continuación)
             Model selected: TVM+G
               -lnL = 5709.6323
               K = 8
               Base frequencies:
                freqA =
                               0.3581
                freqC =
                               0.3186
                fregG =
                               0.0846
                fregT =
                               0.2387
               Substitution model:
                Rate matrix
                               3.9989
                R(a)[A-C] =
                R(b) [A-G] =
                              40.5788
                R(c)[A-T] =
                               3.4119
                R(d)[C-G] =
                               2.3909
                R(e)[C-T] =
                              40.5788
                R(f)[G-T] =
                              1,0000
               Among-site rate variation
                Proportion of invariable sites = 0
                Variable sites (G)
                                                         0.3752
                 Gamma distribution shape parameter =
```

```
-interpretación de la salida de modeltest: 2. AIC = -2 ln L + 2 K; Akaike 1974
   (cantidad de información perdida cuando la realidad es aproximada por un modelo)
                           AKAIKE INFORMATION CRITERION (AIC)
                   Model selected: TrN+G
                    -lnL = 5710.5513
                    K = 6
                    AIC = 11433,1025
                    Base frequencies:
                     freqA =
                                      0.3581
                     freqC =
                                      0.3252
                                      0.0765
                     freqG =
                     freqT =
                                      0.2402
                     Substitution model:
                     Rate matrix
                     R(a)[A-C] =
                                      1.0000
                     R(b)[A-G] =
                                      16,0043
                     R(c) [A-T] =
                                      1.0000
                     R(d)[C-G] =
                                      1.0000
                     R(e)[C-T] =
                                      11.6796
                     R(f)[G-T] =
                     Among-site rate variation
                     Proportion of invariable sites = 0
                     Variable sites (G)
                      Gamma distribution shape parameter = 0.3566
```

				Weights		
			ERTAINTY : Akaike	Weights		
Model	-InL	K	AIC	delta	weight	cumWeight
 TrN+6	5710.5513	6	11433,1025	0.0000	0.2463	0.2463
НКУ+6	5711.9385	5	11433.8770	0.7744	0.1672	0.4135
TIM+G	5710.4355	7	11434.8711	1.7686	0.1017	0.5152
TrN+I+G	5710.5513	7	11435,1025	2.0000	0.0906	0.6058
TVM+G	5709.6323	8	11435.2646	2,1621	0.0835	0.6894
K81uf+ <i>G</i>	5711.8125	6	11435.6250	2,5225	0.0698	0.7591
GTR+G	5708.9224	9	11435.8447	2.7422	0.0625	0.8217
HKY+I+G	5711.9385	6	11435.8770	2.7744	0.0615	0.8832
TIM+I+G	5710.4355	8	11436.8711	3.7686	0.0374	0.9206

© Pablo Vinuesa 2021. @pvinmex vinuesa{at}ccg{dot}unam{dot}mx https://www.ccg.unam.mx/~vinuesa/

Intoducción a la filoinformática – pan-genómica y filogenómica. Diplomado en Bioinformática UAS 2021 https://github.com/vinuesa/intro-filoinfo\_UAS

```
- interpretación de la salida de modeltest: 2. AIC (continuación)

PAUP* Commands Block: If you want to implement the previous estimates as likelihod settings in PAUP*, attach the next block of commands after the data in your PAUP file:

[!
Likelihood settings from best-fit model (TrN+G) selected by AIC in Modeltest 3.7 on Sat May 20 17:12:56 2006
]

BEGIN PAUP;
Lset Base=(0.3581 0.3252 0.0765) Nst=6 Rmat=(1.0000 16.0043 1.0000 1.0000 11.6796) Rates=gamma Shape=0.3566
Pinvar=0;
END;
```

Parameter	Importance	Model-averaged estimates		<ul> <li>Interpretación de la importancia de parámetros</li> </ul>
 f <i>A</i>	1.0000	0.3596	1.	los params. de frec. son
fC	1 0000	0.3223		un componenete esencial
fG	1.0000	0.0794		del modelo
fT	1 0000	0.2387		
TiTv	0.2287	5.4113	2.	Ti/Tv también es
rAC	0.1998	3.7999		significativa
rAG	0.5615	19.9668		
rAT	0.1998	3,2371	3.	El pto. 2 se ratifica en la
rCG	0.1998	2,3657		import, de rAG y rCT res-
rCT	0.5615	14.9960		pecto a tasas de Tv
pinv(I)	0.0000	0.3717		· •
alpha(G)	0.7311	0.3621	4	El parámetro alpha (uso de
pinv(IG)	0.2689	0.0000	- 1	distrib. gamma) es mucho
alpha(IG)	0.2689	0.3621		más imp. que asumir sólo
Values have bee	en rounded			pinv.
(I):	averaged using or	nlv +I models.		
(G):	averaged using or			
(B). (IG):	averaged using or averaged using or			

#### Modelos de base evaluados por Modeltest

Table 1. Model names. Some models have no reference (TNef, K81uf, TIMef, TIM, TVMef, TVM), they are just some variations of some existing models, and they were no developed, only named, by D, Posada.

Model	Name					
JC	Jukes and Cantor (Jukes and Cantor, 1969)					
F81	Felsenstein 81 (Felsenstein, 1981)					
K80	Kimura 80 (=K2P) (Kimura, 1980)					
HKY	Hasegawa, Kishino, Yano 85 (Hasegawa, Kishino and Yano, 1985)					
TNef	Tamura-Nei equal frequencies					
TN	Tamura-Nei (Tamura and Nei, 1993)					
K81	Two transversion-parameters model 1 (=K81=K3P) (Kimura, 1981)					
K81uf	Two transversion-parameters model 1 unequal frecuencies					
TIMef	Transitional model equal frequencies					
TIM	Transitional model					
TVMef	Transversional model equal frequencies					
TVM	Transversional model					
SYM	Symmetrical model (Zharkihk, 1994)					
GTR	General time reversible (=REV) (Tavaré, 1986)					

© Pablo Vinuesa 2021. @pvinmex vinuesa{at}ccg{dot}unam{dot}mx https://www.ccg.unam.mx/~vinuesa/

Intoducción a la filoinformática – pan-genómica y filogenómica. Diplomado en Bioinformática UAS 2021 https://github.com/vinuesa/intro-filoinfo\_UAS

#### Modelos de base evaluados por Modeltest

Table 2. Model parameters. The substitution codes are just two ways of indicating the substitution scheme. Any of these models can ignore rate variation or include invariable sites (+I), rate variation among sites (+G), or both (+I+G).

Model	Free parameters	Base frequencies	Substitution rates	Substitution code 1	Substitution code 2
JC	0	equal	a=b=c=d=e=f	000000	aaaaaa
F81	3	unequal	a=b=c=d=e=f	000000	aaaaaa
K80	1	equal	a=c=d=f, b=e	010010	abaaba
HKY	4	unequal	a=c=d=f, b=e	010010	abaaba
TNef	2	equal	a=c=d=f, b, e	010020	abaaca
TN	5	unequal	a=c=d=f, b, e	010020	abaaca
K81	2	equal	a=f, c=d, b=e	012210	abccba
K81uf	5	unequal	a=f, c=d, b=e	012210	abccba
TIMef	3	equal	a=f, c=d, b, e	012230	abccda
TIM	6	unequal	a=f, c=d, b, e	012230	abccda
TVMef	4	equal	a, c, d, f, b=e	012314	abcdbe
TVM	7	unequal	a, c, d, f, b=e	012314	abcdbe
SYM	5	equal	a, c, d, f, b, e	012345	abcdef
GTR	8	unequal	a, c, d, f, b, e	012345	abcdef